

Inteligência de Negócio

Primeiro Trabalho

Gabriel Leite Fonseca e Rafael Calazans de Jesus

17/05/2026

Parte 1 - Modelagem Dimensional

1. Identificando os processos de negócio.

A partir das questões levantadas, pode-se identificar dois processos de negócios relevantes: um processo relacionado a viagens e outro referente a entregas.

2. Explicando a granularidade

2.1. Indicando granularidade

A granularidade do processo de negócio referente a viagens corresponde as informações relevantes a cada viagem. No caso, cada linha do fato viagem possui informações relevantes que ajudam a responder as questões levantadas, sendo elas: a rota da viagem, o motorista, o veículo, a data de chegada, o tempo da viagem, diferença de tempo previsto e o tempo efetivamente gasto na viagem e o número de encomendas levadas na viagem. Já em relação ao processo de negócio referente a entregas, nota-se que cada linha representa informações importantes referentes a uma entrega, sendo elas: o cliente da entrega, a encomenda, a data da entrega, a situação da entrega (entregue, atrasada ou destinatário ausente).

2.2. Modelos Data Mart




Figure 1: Data Mart Entrega




Figure 2: Data Mart Viagem

Parte 2 – Processo de ETL

1. Objetivo

A segunda etapa do trabalho teve como objetivo realizar o processo de ETL (Extract, Transform and Load) para o Data Mart relacionado às análises de entregas da empresa Guepardo Logística.

O processo foi desenvolvido utilizando Python, com apoio das bibliotecas **Polars**, **SQLAlchemy** e **Pandas**, realizando a extração dos dados do banco transacional MySQL, os tratamentos necessários e a carga das tabelas dimensionais e da tabela fato em um banco dimensional.

O código utilizado se encontra disponível em <https://github.com/Gabedf/DataMatarEntregas>

2. Tecnologias Utilizadas

Durante o desenvolvimento do processo ETL foram utilizadas as seguintes tecnologias:

Tecnologia	Finalidade
Python	Linguagem principal do processo ETL
Polars	Manipulação e transformação de dados
SQLAlchemy	Conexão com o banco MySQL
Pandas	Escrita das tabelas no banco dimensional
MySQL	Banco de dados transacional e dimensional
dotenv	Gerenciamento de variáveis de ambiente

3. Estrutura do Processo ETL

O processo foi dividido em três etapas principais:

1. Extração dos dados do banco transacional;
2. Transformação e consolidação dos dados;
3. Carga das dimensões e da tabela fato no Data Mart.

4. Extração dos Dados

Inicialmente, foi criada a conexão com o banco de dados transacional utilizando SQLAlchemy e variáveis de ambiente.

```
source_url = (  
    f"mysql+pymysql://{os.getenv('DB_USER')}: "  
    f"{os.getenv('DB_PASSWORD')}@"  
    f"{os.getenv('DB_HOST')}: "  
    f"{os.getenv('DB_PORT')}/ "  
    f"{os.getenv('DB_SOURCE')}"  
)
```

Após a conexão, foram definidas consultas SQL para extração das tabelas utilizadas no Data Mart de entregas.

As principais tabelas utilizadas foram:

- clientes
- cidades
- estados

- encomendas
- entregas
- tiposervico
- situacaoentregas

Os dados foram carregados para DataFrames Polars utilizando `pl.read_database()`.

Exemplo:

```
clientes = pl.read_database(
    query=query_clientes,
    connection=engine
)
```

Além disso, a dimensão Data foi carregada a partir da planilha disponibilizada no trabalho (Ch3-SampleDateDim.xls).

```
data = pl.read_excel(
    'data/raw/Ch3-SampleDateDim.xls',
    sheet_name='LoadDates'
)
```

5. Transformações Realizadas

5.1 Construção da Dimensão Encomenda

A dimensão encomenda foi construída a partir da junção das tabelas `encomendas` e `tiposervico`.

As informações consolidadas foram:

- Tipo de serviço;
- Peso;
- Volume;
- Valor do frete.

Foi criado também um identificador dimensional (`idDimEncomenda`) utilizando `with_row_index()`.

```
dim_encomenda = (
    dim_encomenda
    .with_row_index(name='idDimEncomenda', offset=1)
)
```

5.2 Construção da Dimensão Cliente

A dimensão cliente foi criada a partir da junção entre:

- clientes
- cidades
- estados

As informações consolidadas foram:

- Nome do cliente;
- Tipo do cliente;
- Cidade;
- Estado.

Também foi criado um identificador dimensional (`idDimCliente`).

Exemplo do tratamento:

```
dim_cliente = (  
  clientes  
  .join(  
    cidade,  
    on='id_cidade',  
    how='left'  
  )  
)
```

5.3 Construção da Dimensão Data

A dimensão Data foi construída utilizando a planilha disponibilizada no AVA.

Os atributos selecionados foram:

- Dia;
- Mês;
- Ano.

```
dim_data = (  
  data  
  .select(['date key', 'day num in month', 'month', 'year'])  
)
```

5.4 Construção da Tabela Fato

A tabela fato foi chamada de `fatoEntrega`.

Inicialmente foi calculado o tempo de entrega em minutos utilizando a diferença entre:

- `data_entrega`
- `data_saida_entrega`

```
(pl.col("data_entrega") - pl.col("data_saida_entrega"))
```

Também foi criada a chave da dimensão data (`idDimDataEntrega`) baseada na data da entrega.

Posteriormente foram realizados joins entre:

- `entregas`
- `dim_encomenda`
- `dim_cliente`
- `situacaoentregas`

As métricas e dimensões finais da tabela fato foram:

Campo	Descrição
<code>idDimCliente</code>	Cliente associado
<code>idDimEncomenda</code>	Encomenda associada
<code>idDimDataEntrega</code>	Data da entrega
<code>tempoEntrega</code>	Tempo total da entrega
<code>situacaoEntrega</code>	Situação da entrega

6. Estrutura Dimensional Gerada

O modelo dimensional implementado foi composto pelas seguintes tabelas:

Dimensões

- `dim_cliente`
- `dim_encomenda`
- `dim_data`

Tabela Fato

- fatoEntrega

O modelo segue o padrão estrela (Star Schema), centralizando a tabela fato e conectando-a às dimensões.

7. Criação do Banco Dimensional

Após as transformações, foi criado o banco dimensional chamado:

```
data_mart_entregas
```

Código utilizado:

```
conn.execute(text(  
    "CREATE DATABASE IF NOT EXISTS data_mart_entregas"  
))
```

8. Carga das Tabelas

Antes da carga, as tabelas existentes foram removidas para evitar inconsistências.

```
conn.execute(text("DROP TABLE IF EXISTS fatoEntrega"))
```

A carga foi realizada utilizando `to_sql()` do Pandas.

Exemplo:

```
dim_cliente.to_pandas().to_sql(  
    name='dim_cliente',  
    con=engine_dw,  
    if_exists='fail',  
    index=False  
)
```

As tabelas carregadas foram:

- dim_cliente
- dim_encomenda
- dim_data
- fatoEntrega

9. Banco Transacional Utilizado

O banco transacional utilizado foi o `dblogistica`, contendo todas as tabelas fornecidas no modelo relacional do trabalho.

Foram inseridos registros em todas as tabelas necessárias para o funcionamento do Data Mart de entregas, incluindo:

- clientes
- encomendas
- entregas
- cidades
- estados
- tiposervico
- situacaoentregas

Exemplo de inserção presente no backup:

```
INSERT INTO `tiposervico`  
VALUES  
(1, 'Normal'),  
(2, 'Expressa'),  
(3, 'Economica');
```

10. Resultados Obtidos

Ao final do processo ETL foi possível:

- Consolidar os dados do sistema transacional;
- Criar dimensões analíticas;
- Construir uma tabela fato orientada à análise de entregas;
- Disponibilizar uma base dimensional preparada para consultas analíticas e dashboards.

O Data Mart criado permite responder perguntas de negócio como:

- Tempo médio de entrega;
- Entregas em atraso;
- Desempenho por tipo de serviço;
- Análises por cliente;
- Análises por período.